Segmentation explicable des clients Olist

Projet Challenge 3 – Application web de segmentation explicable · Data Mining, ENSI (II3-IF) · Mohamed Aljene

Données

Brazilian E-Commerce Public Dataset by Olist (Kaggle) : données réelles et anonymisées, licence CC BY-NC-SA 4.0. « Thanks to Olist for releasing this dataset. » Montants en réals brésiliens (R$).

96 096 clients → 93 350 avec au moins une commande livrée → 81 006 dans la période retenue (achats du 2017-01-01 au 2018-06-30 ; fin de 2016 = période d'essai ; après juin 2018 = coupure de l'extraction). 80 % pour apprendre (64 805 clients), 20 % mis de côté jusqu'à l'évaluation finale.

Méthode

- Profil par client : 8 variables (Récence, Fréquence, Montant, part des frais de port, mensualités, articles par commande, délai de livraison, écart à la date promise). La note d'avis n'entre jamais dans le clustering.
- Préparation apprise sur les 80 % : log(1 + x) des variables positives asymétriques, écrêtage aux 0,5e et 99,5e centiles, standardisation ; réappliquée telle quelle.
- ACP normée : 5 axes retenus (82,0 % de l'information) par la règle max(Kaiser, part cumulée ≥ 70 %).
- Algorithmes comparés : K-Means (référence, 8 variables), CAH de Ward, classification mixte (CAH sur les axes puis consolidation par K-Means), HDBSCAN.
- Les choix principaux ont été écrits et poussés avant le calcul ; les exceptions sont tracées dans le journal docs/CHOIX.md.

Choix du nombre de segments

Règle : k admissible si le plus petit segment ≥ 2 %, l'ARI bootstrap moyen ≥ 0,80 et chaque Jaccard ≥ 0,60 ; puis la plus petite somme des rangs (silhouette, Calinski-Harabasz, Davies-Bouldin).

k	2	3	4	5	6	7	8
somme des rangs	21	18	10	7	8	8	12
ARI bootstrap moyen	0,98	0,91	0,80	0,91	0,98	0,98	0,94

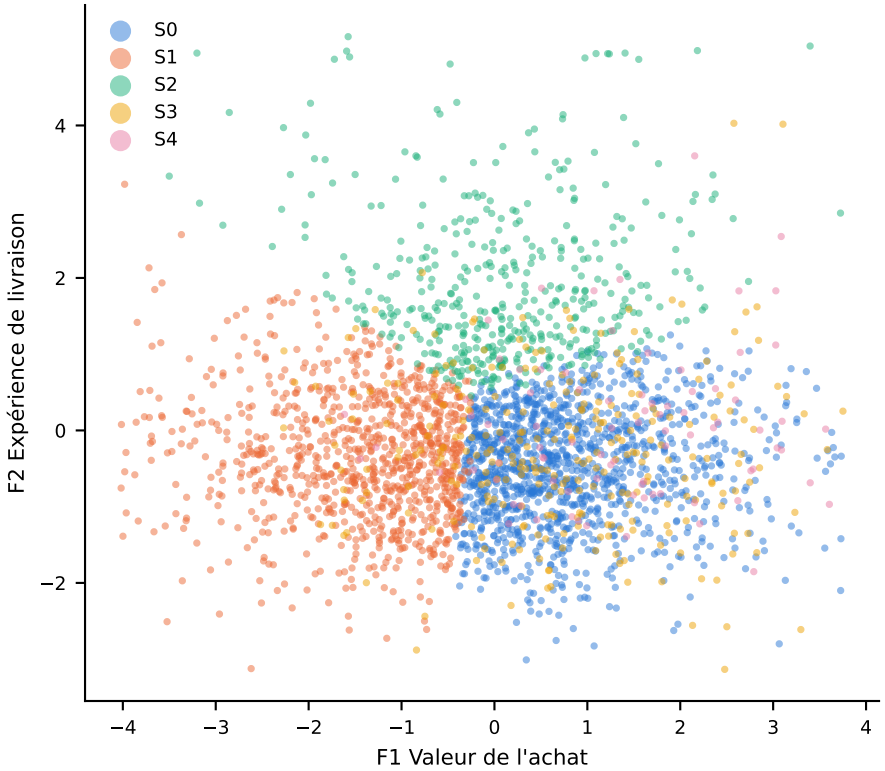
k = 5 retenu ; critère métier validé (une action différente par segment). Silhouette 0,200 (1,7 % de clients négatifs) : un nuage continu, découpé plutôt que naturellement séparé.

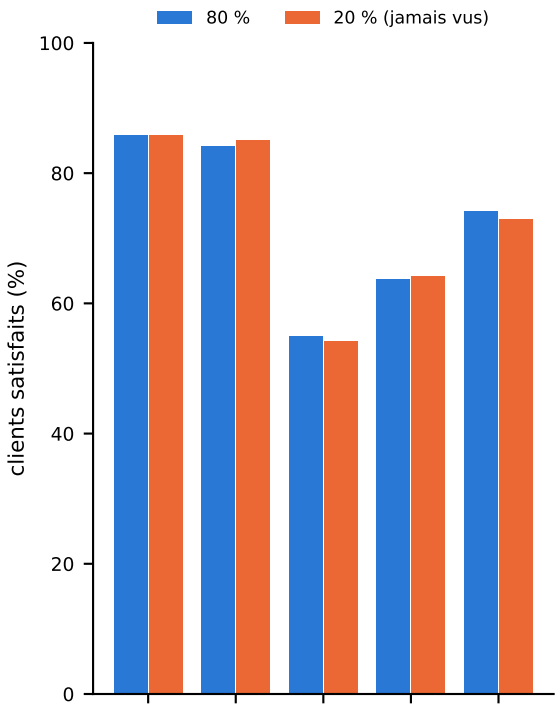
Les 5 segments

segment	clients	part du CA	satisfaits 80 %	satisfaits 20 %
S0 Gros achats en plusieurs fois	40,3 %	57,0 %	85,7 %	85,8 %
S1 Petits achats, livraison chère	31,9 %	8,9 %	84,0 %	85,0 %
S2 Livraison lente ou en retard	15,7 %	15,3 %	54,9 %	54,2 %
S3 Achats de plusieurs articles	9,1 %	13,5 %	63,7 %	64,1 %
S4 Clients qui recommandent	3,0 %	5,3 %	74,1 %	72,8 %

- S0 « Gros achats en plusieurs fois » : Offres premium et paiement en plusieurs fois.
- S1 « Petits achats, livraison chère » : Livraison gratuite à partir d'un seuil, pour grossir le panier.
- S2 « Livraison lente ou en retard » : Geste commercial et suivi de la logistique.
- S3 « Achats de plusieurs articles » : Lots et ventes croisées.
- S4 « Clients qui recommandent » : Programme de fidélité.

Carte de l'ACP et satisfaction





Évaluation

Externe (note d'avis, « satisfait » si note ≥ 4) : ARI 0,067, NMI 0,039, faibles par nature avec une étiquette à deux classes. Le segment S2 est lié à la note par construction (retards) : clients livrés à l'heure 82,0 % de satisfaits, en retard 24,9 %.

Finale, sur les 20 % mis de côté, ouverte une seule fois, attentes écrites avant l'ouverture : 12 attentes atteintes sur 12 (tailles des segments, silhouette, atypiques, frontière, fidélité de l'arbre, satisfaction par segment et ordre des segments, indices externes).

Explicabilité

Arbre de décision de substitution (profondeur 4) : fidélité 87,42 % sur les 80 %, 87,75 % sur les 20 %, 13 règles traduites en phrases. Pour chaque client : segment, distance au centre, indicateurs « atypique » (95e centile du segment) et « à la frontière », variables qui l'éloignent du client moyen et du centre de son segment.

Constat : dans S3 « Achats de plusieurs articles », les clients dont une commande avait plusieurs vendeurs sont nettement moins satisfaits (écart de -28,0 points sur les 80 %, -35,3 sur les 20 %) : une piste (plusieurs colis), pas une preuve.

Limites

- Nuage continu : silhouettes faibles ; une découpe concurrente apparaît dans 6 tirages bootstrap sur 50 (S2 y disparaît).
- Les 20 % viennent de la même période : la segmentation devrait être refaite régulièrement (habitudes et délais changent).
- L'axe F4 de l'ACP est un axe du temps (Récence) ; le nombre d'axes est fragile (69,97 % à F4 pour un seuil de 70 %).
- API sur l'offre gratuite de Render : mise en veille après 15 minutes sans requête (fait de l'hébergeur ; premier appel lent).

Réalisation

Code : https://github.com/aljene307/segmentation-xai (licence MIT ; données dérivées sous CC BY-NC-SA 4.0). API FastAPI : https://segmentation-xai-api.onrender.com. Application Streamlit : voir le README. Journal complet des choix : docs/CHOIX.md.